SVEUČILIŠTE U ZAGREBU

FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

Korištenje ugrađenih reprezentacija (embedding) za analizu sekvenci DNA pomoću dubokog učenja

Fran Kufrin

Voditelj: *Doc. dr. sc. Krešimir Križanović*

Zagreb, 4, 2025

Sadržaj

1. Uvod 1

2. Ugrađene reprezentacije podataka 2

2.1 Word2Vec 4

2.2 FastText 5

3. Ugrađene reprezentacije kod analize DNA sekvenci 6

3.1 DNA 6

3.2 Reprezentacija DNA pomoću k-mer embeddinga i DNABERT model 7

3.3 DNABERT 7

3.3.1 Tokenizacija i k-mer slicing 8

3.3.2 Embedding sloj 8

3.3.3 Pozicijsko kodiranje 9

3.3.4 Self-attention mehanizam 9

3.3.5 Feedforward slojevi i fine-tuning 9

3.4 Nucleotide Transformer 9

3.4.1 Struktura i tokenizacija 10

3.4.2 Priprema podataka 10

3.4.3 Pozicijsko kodiranje 10

4. Usporedba korištenja ugrađenih i klasičnih reprezentacija 11

4.1 Zadatak 11

4.2 Priprema podataka 11

4.3 Model 12

4.4 Rezultati i evaluacija 12

5. Zaključak 16

6. Sažetak 17

7. Literatura 18

1. Uvod

Analiza DNA sekvenci jedan je od ključnih izazova u bioinformatici. Suvremene tehnologije, poput sekvenciranja nove generacije (NGS), omogućile su brzo generiranje ogromnih količina podataka. Međutim, njihova obrada, interpretacija i ekstrakcija korisnih informacija zahtijevaju sve sofisticiranije računalne metode.

Duboko učenje, grana strojnog učenja temeljena na neuronskim mrežama, pokazalo je izniman potencijal u otkrivanju kompleksnih obrazaca u nestrukturiranim podacima. No, jedan od osnovnih preduvjeta za uspješnu primjenu dubokog učenja jest prikladna reprezentacija ulaznih podataka. Tradicionalne metode, poput one-hot kodiranja nukleotida, zanemaruju semantičke sličnosti između podnizova te slabo skaliraju s dužinom sekvence.

Zbog toga se u bioinformatici sve češće koriste ugrađene (eng. embedded) reprezentacije podataka, izvorno razvijene za obradu prirodnog jezika. One omogućuju preslikavanje nenumeričkih podataka, poput k-mera u DNA, u kontinuirani vektorski prostor u kojem se semantički slični elementi nalaze blizu jedni drugima. Time modeli mogu učinkovitije učiti biološki relevantne obrasce.

Primjenom pristupa kao što su Word2Vec, FastText, DNABERT i Nucleotide Transformer moguće je DNA sekvence prikazati u obliku vektora optimalnih za duboko učenje, što značajno poboljšava točnost i generalizacijsku sposobnost modela u rješavanju bioinformatičkih zadataka.

2. Ugrađene reprezentacije podataka

Pošto modeli temeljeni na neuronskim mrežama nemogu raditi sa podacima poput riječi ili slova, jako je važno te podatke pretvoriti u numerički tip. Jedan od najčešćih načina kako to ostvariti je pomoću one-hot vektora. Takva reprezentacija je dosta jednostvna i lagana za koristiti, ali ona ima svoja ograničenja koja uključuju visoku dimenzionalnost, rijetkost vektora i nemogućnost izražavanja semantičke sličnosti između podataka.

Ugrađene reprezentacije rješavaju ove probleme projektiranjem podataka u kontinuirani, niskodimenzionalni vektorski prostor. Svakom elementu pridružuje se realni vektor tako da su semantički slični elementi smješteni blizu u prostoru.

Evo pojednostavljenog primjera ugrađenih reprezentacija riječi (word embeddinga) za vrlo mali vokabular od 6 riječi, gdje je svaka riječ predstavljena kao trodimenzionalni vektor:

mačka [0.2, -0.4, 0.7]

pas [0.6, 0.1, 0.5]

jabuka [0.8, -0.2, -0.3]

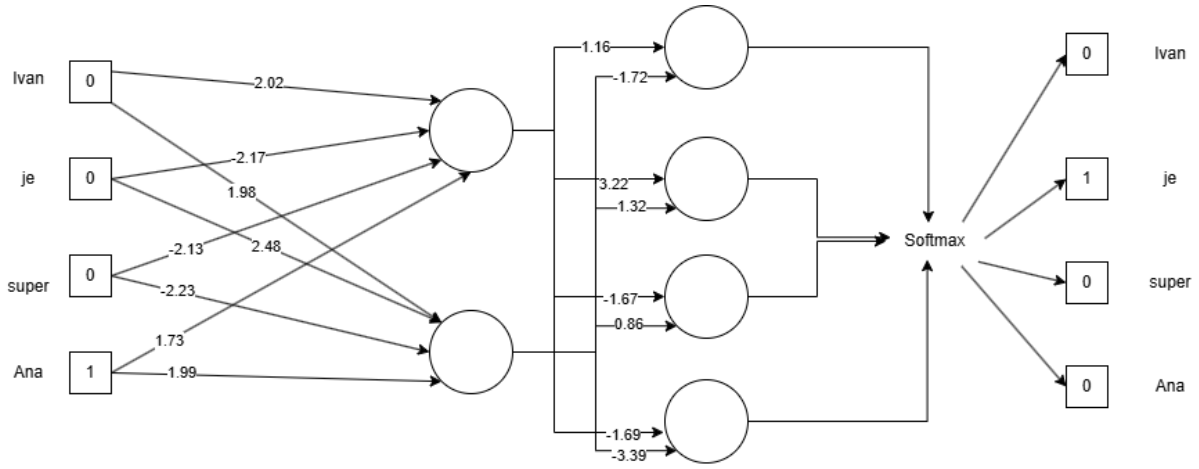
naranča [0.7, -0.1, -0.6]

sretan [-0.5, 0.9, 0.2]

tužan [0.4, -0.7, -0.5]

U ovom primjeru, svaka riječ (npr. „mačka“, „pas“, „jabuka“) povezana je s jedinstvenim vektorom. Vrijednosti u vektoru predstavljaju položaj riječi u kontinuiranom trodimenzionalnom vektorskom prostoru. Očekuje se da riječi sličnog značenja ili koje se pojavljuju u sličnim kontekstima imaju slične vektorske reprezentacije. Na primjer, vektori za „mačka“ i „pas“ nalaze se blizu jedan drugome, što odražava njihovu semantičku povezanost. Slično tome, vektori za „sretan“ i „tužan“ imaju suprotne smjerove, što ukazuje na njihova suprotna značenja[1].

Takve reprezentacije podataka možemo dobiti treniranjem jednostavne neuronske mreže.



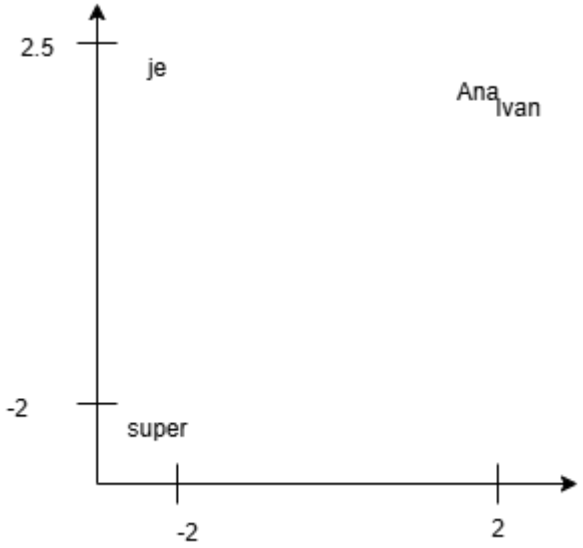
slika 2.1: Prikaz određivanja ugrađenih reprezentacija riječi pomoću neuronske mreže

Neuronska mreža prikazana na slika 2.1 demonstrira kako se mogu dobiti ugrađene reprezentacije podataka pomoću neuronskih mreža. Mreža se satoji od ulaznog sloja, skrivenog sloja te izlaznog sloja gdje se primjenjuje softmax funkcija. Na ulaznom sloju se šalju jedinice u mrežu za riječi za koje se želi predvidjeti slijedeća riječ u nizu. Nakon ulaznog sloja slijedi jednostavni skriveni sloj gdje se nalazi određen broj neurona sa funkcijom indetiteta kao aktivacijskom funkcijom. Broj neurona u skrivenom sloju određuje dimenzionalnost ugrađene reprezentacije koje ćemo dobiti na kraju treniranja. U primjeru na slika 2.1 vidimo da imamo dva neurona što znači da će reprezentacija biti dvodimenzionalna.Zatim slijedi izlazni sloj na koji se primjenjuje softmax funkcija kako bi dobili vjerojatnosnu distribuciju izlaza.

Zamislimo da imamo mali dataset od dvije rečenice: „Ivan je super” i „Ana je super”. Iz tih rečenica možemo vidjeti da je naš vokabular veličine četiri te se sastoji od riječi „Ivan”, „je”, „super” i „Ana”. Tim skupom podataka treniramo neuronsku mrežu tako da na ulazu šaljemo jednu riječ te na izlazu želimo dobiti slijedeću riječ u zadanom nizu. Tako na slika 2.1, ako gledamo niz „Ana je super”, možemo vidjeti da na ulaz mreže šaljemo riječ „Ana” (označeno jedinicom) i na izlazu očekujemo da će riječ „je” imati najveću vjerojatnost.

Nakon što istreniramo neuronsku mrežu, težine povezane sa svakom riječi u vokabularu označava njihovu ugrađenu reprezentaciju, tako možemo vidjeti da ugrađena vektorska reprezentacija za riječ „Ana” je [1.73 1.99].

Dobivene reprezentacije možemo vidjeti prikazane na slika 2.2. Na prikazanom grafu možemo uočiti da riječi slične semantike se nalaze blizu u prostoru npr. riječi „Ana” i „Ivan”. To nam omogućuje bolju reprezentaciju podataka čime se omogućuje učinkovitije učenje i bolja generalizacija kod dubokih modela.

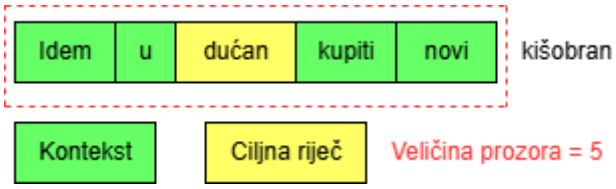


slika 2.2: Prikaz ugrađenih reprezentacija

2.1 Word2Vec

Jedan od najutjecajnijih pristupa za učenje ugrađenih reprezentacija jest Word2Vec, koji je 2013. godine razvio tim iz Google-a. Word2Vec radi na sličan princip kao prošli prikazani primjer. Temeljna pretpostavka Word2Vec-a je da riječi koje se pojavljuju u sličnim kontekstima imaju slično značenje što znači da će imati slične vektorske reprezentacije. Word2Vec model je zapravo sastavljen od dva slična modela.

Prvi model se zove CBOW (Continuous Bag of Words). Ovaj model nastoji predvidjeti ciljnu riječ na temelju okolnih kontekstnih riječi unutar zadanog prozora. Koristi kontekstne riječi za predikciju ciljne riječi, a naučeni embedding vektori pritom hvataju semantičke odnose među riječima[1].



Slika 2.3:Prikaz konteksta i ciljne riječi za CBOW model

U CBOW modelu se definira veličina prozora te se srednja riječ uzima kao ciljna riječ, a ostale riječi kao kontekst. CBOW kao ulaz uzima kontekst te pokušava predvidjeti ciljnu riječ. Ovaj model odlično radi za riječi koje se često pojavljuju.

Drugi model se zove skip-gram. Skip-gram radi na potpuno suprotan način od CBOW-a. Ovdje uzimamo jednu ulaznu riječ i očekujemo da nam model kaže koje riječi bi se trebale nalaziti u njezinoj okolini[2]. Skip-gram modeli dobro funkcioniraju

na malim skupovima podataka i mogu bolje reprezentirati riječi koje se rjeđe pojavljuju[2].

2.2 FastText

FastText je model za učenje ugrađenih reprezentacija riječi koji su razvili istraživači iz Facebook AI Research (FAIR). Temelji se na modelu Word2Vec, ali umjesto da uči vektor za cijelu riječ, FastText uči vektore za njene podnizove. Time omogućuje bolju generalizaciju i bolje hvatanje semantičkih odnosa, osobito za riječi koje su rijetke ili čak nepostojeće kod treniranja. U Word2Vec-u svaka riječ ima jedan vektor, dok kod FastText-a svaka riječ se razlaže na manje dijelove (n-grame), i konačni vektor riječi je prosjek vektora svih njezinih n-grama.

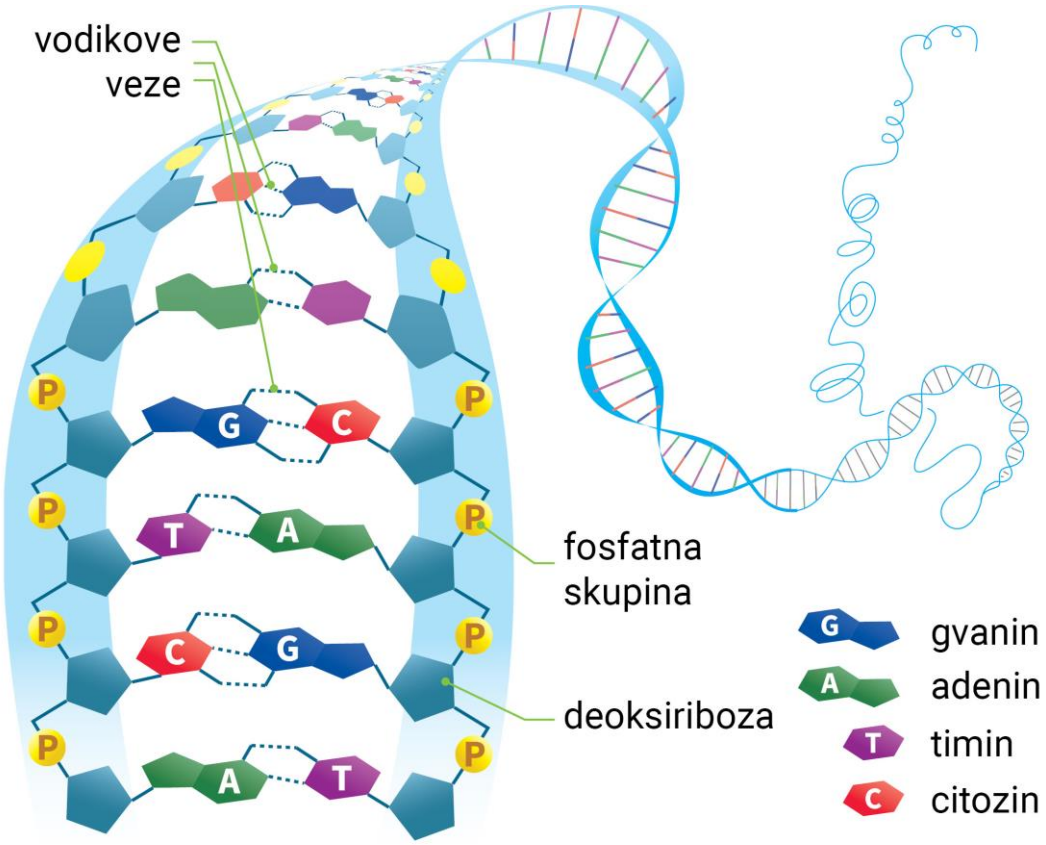
Npr. za riječ „apple“ i n-grame dužine 3, FastText stvara slijedeće podnizove: <ap, app, ppl, ple i le>. Vektor za riječ „apple“ je prosjek vektora njegovih podnizova. Time FastText može generirati vektore i za riječi koje nikada nije vidio. To je vrlo korisno za jezike s bogatom morfologijom.

3. Ugrađene reprezentacije kod analize DNA sekvenci

3.1 DNA

Deoksiribonukleinska kiselina (DNA) je molekula koja sadrži nasljedne upute potrebne za razvoj, funkcioniranje, rast i razmnožavanje svih poznatih živih organizama i mnogih virusa. Građena je od dvije komplementarne niti koje tvore strukturu poznatu kao dvostruka spirala (double helix). Svaka nit sastoji se od nukleotida, koji se sastoje od tri dijela: šećerne skupine, fosfatne skupine i dušične baze.

Postoje četiri vrste dušičnih baza koje se pojavljuju u DNA: adenin (A), citozin (C), gvanin (G) i timin (T).



Slika 3.1: Prikaz DNA molekule [4]

U bioinformatici, DNA se najčešće predstavlja kao jednostavan niz znakova sastavljen od slova A, C, G i T. Na primjer, jedan dio DNA može izgledati ovako: „ACGTGCTAGCTAGTTAGC...".

Ovakav prikaz omogućuje primjenu algoritama iz područja strojnog učenja i obrade prirodnog jezika, jer se sekvence DNA mogu tretirati kao "tekst" u kojem se traže obrasci, pravilnosti ili anomalije, slično kao kod analize rečenica u ljudskom jeziku.

Dužina DNA molekule može biti izuzetno velika; ljudski genom, primjerice, sadrži oko 3 milijarde parova baza. S obzirom na tu količinu podataka, korištenje metoda dubokog učenja za automatsku analizu postaje vrlo korisno. Te metode mogu pomoći u otkrivanju funkcionalnih elemenata DNA, poput promotora, gena ili regija koje reguliraju ekspresiju gena.

DNA se dakle promatra kao niz simbola koji je moguće pretvoriti u vektorske reprezentacije (embeddinge), čime se omogućuje primjena modela dubokog učenja za klasifikaciju, detekciju uzoraka ili predikciju bioloških funkcija.

3.2 Reprezentacija DNA pomoću k-mer embeddinga i DNABERT model

Za razliku od prirodnog jezika, gdje su osnovne jedinice riječi ili tokeni, u genomskim analizama sekvence DNA se često pretvaraju u nizove k-merova, kratkih preklapajućih podnizova dužine k. Na primjer, DNA niz ATGCGT može se za k = 3 prikazati kao sljedeći niz k-merova: [ATG, TGC, GCG, CGT].

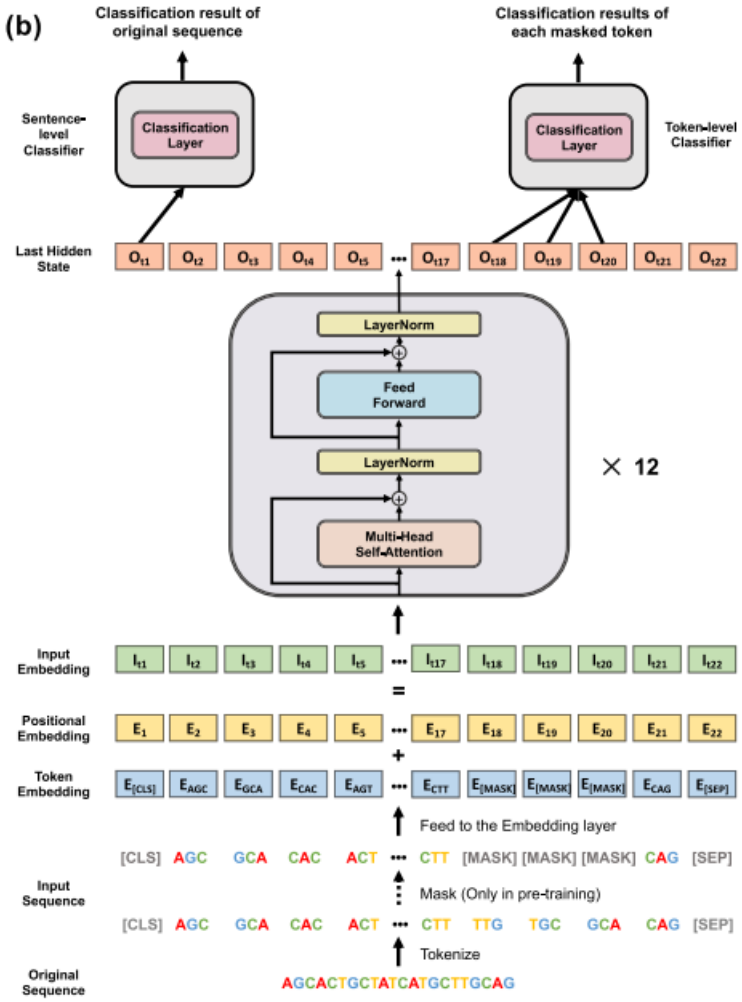
Ova tehnika omogućuje modelu da lakše uoči lokalne obrasce koji su biološki relevantni, poput promotorskih regija, motiva za vezanje proteina i slično. Korištenjem preklapajućih k-merova model dobiva detaljniji uvid u sekvencu i kontekst svake pozicije.

Svaki od k-merova se zatim mapira u vektor, tj. numeričku reprezentaciju u višedimenzionalnom prostoru, koja se tijekom predtreniranja optimizira kako bi sažela biološki kontekst u kojem se k-mer pojavljuje. Ti vektori tvore embedding koji služi kao ulaz u duboki model.

3.3 DNABERT

DNABERT je prilagodba poznatog BERT modela za obradu DNA sekvenci. Umjesto riječi, model uči reprezentacije k-merova, i koristi arhitekturu temeljenju na transformerima, što mu omogućuje hvatanje dugoročnih odnosa i konteksta u DNA.

DNABERT model se trenira u dvije faze. Prva faza je predtreniranje u kojoj model uči općenite reprezentacije iz velikog skupa nepovezanih podataka koristeći zadatke poput predviđanja maskiranih tokena (Masked Language Modeling). U kontekstu DNABERT-a to znači da model uči razumjeti strukturu DNA analizirajući k-mere i njihov kontekst u genomskim sekvencama. Fine-tuning je druga faza u kojoj se već predtreniran model dodatno trenira na manjem, specifičnom skupu podataka kako bi riješio konkretan zadatak, poput klasifikacije promotora. Tijekom fine-tuninga se često treniraju samo zadnji slojevi modela, dok se ostatak modela može djelomično ili potpuno zamrznuti.



Slika 3.2: prikaz DNABERT modela

Model DNABERT koristi sljedeće ključne korake:

3.3.1 Tokenizacija i k-mer slicing

Ulazna DNA sekvenca prvo se dijeli u podnizove fiksne duljine (tipično 510 nukleotida), bez preklapanja između tih podnizova. Svaki takav podniz zatim se pretvara u preklapajuće k-merove. Na primjer, za k = 6, niz ATGCGTAC daje:

[ATGCGT, TGCGTA, GCGTAC].

3.3.2 Embedding sloj

Svaki k-mer se mapira u vektor (embedding) dimenzije npr. 768. Ti vektori nisu unaprijed definirani (kao kod Word2Vec-a), već se uče tijekom predtreniranja modela pomoću zadatka Masked Language Modeling (MLM). U tom zadatku nasumični k-

merovi se zamjenjuju s [MASK] tokenom, a model mora naučiti predvidjeti koji k-mer tu nedostaje na temelju okolnog konteksta. Primjer: [AGC, GCT, [MASK], TTA, TAG]

Cilj je naučiti rekonstruirati originalni k-mer, što tjera model da u embedding svakog k-mera "ugradi" informacije o značenju u različitim kontekstima.

3.3.3 Pozicijsko kodiranje

Budući da transformeri nemaju ugrađeni osjećaj redoslijeda tokena, model koristi pozicijsko kodiranje koje se dodaje svakom k-mer embeddingu. Ovo kodiranje omogućuje modelu da razlikuje istovjetne k-merove koji se pojavljuju na različitim pozicijama. Bez ovog kodiranja, model ne bi znao razliku između ATG na početku ili na kraju sekvence. Pozicijsko kodiranje se u DNABERT-u uči tijekom predtreniranja i može biti trenirano (learnable) ili unaprijed definirano (npr. sinusoidno), ovisno o implementaciji.

3.3.4 Self-attention mehanizam

Nakon što svaki k-mer dobije svoj vektor (embedding + pozicija), ti vektori se prosljeđuju u transformer blokove koji sadrže self-attention mehanizam. Taj mehanizam omogućava svakom vektoru da "pogleda" sve druge vektore u sekvenci i teži više onima koji su relevantniji za njega.

Rezultat self-attentiona je da svaki izlazni vektor postaje obogaćen informacijom o cijelom kontekstu sekvence, npr. vektor koji predstavlja k-mer CGTACG nakon attentiona sadrži ne samo informaciju o tom k-meru, nego i o njegovim biološki važnim susjedima.

3.3.5 Feedforward slojevi i fine-tuning

Na izlazu iz transformer blokova nalaze se feedforward (dense) slojevi koji dodatno transformiraju vektore. U fazi fine-tuninga, na te izlazne vektore dodaje se poseban klasifikacijski sloj ili drugi model-specifičan sloj koji se trenira za specifičan zadatak (npr. klasifikacija promotora, predikcija veznih mjesta, itd.), dok se cijeli model (uključujući embeddinge) može dodatno prilagoditi novom zadatku

3.4 Nucleotide Transformer

Nucleotide Transformer (NT) predstavlja najnapredniji pristup u području jezičnog modeliranja genomskih sekvenci, oslanjajući se na paradigmu velikih jezičnih modela (LLM) primijenjenu na biološke podatke. Riječ je o obitelji modela temeljenih na transformer arhitekturi, treniranih na više stotina milijardi nukleotidnih tokena iz različitih genoma ljudi i drugih vrsta. U usporedbi s DNABERT-om NT je znatno veći, raznovrsniji i skalabilniji model osposobljen za različite zadatke iz domene bioinformatike.

3.4.1 Struktura i tokenizacija

NT koristi specijalizirani tokenizator temeljen na šestmerima (6-mer). Ukupno 4,096 mogućih kombinacija šest nukleotida (A, T, C, G) čini osnovni vokabular, kojem su dodani dodatni tokeni: pet za pojedinačne nukleotide (A, T, C, G, N) te tri specijalna tokena: CLS (početak sekvence), MASK (maskiranje) i PAD (popunjavanje). Ukupna veličina vokabulara iznosi 4,104 tokena. Tokenizacija sekvence započinje s CLS tokenom, a sekvenca se zatim dijeli na šestmere s lijeva na desno bez preklapanja, s fallback mehanizmom na pojedinačne tokene kada to nije moguće (npr. u prisutnosti slova N ili kraće sekvence).

3.4.2 Priprema podataka

Modeli su trenirani na velikim genomskim datasetima koji uključuju ljudski referentni genom, multispecies genomsku kolekciju i podatke iz 1000 Genomes projekta. Genomi su segmentirani u preklapajuće podsekvence od 6100 nukleotida, s preklapanjem od 50 nukleotida na rubovima. Tijekom svake epohe, za svaki segment se nasumično odabire početna pozicija (0–100), a zatim se uzima niz koji proizvodi 1,000 tokena.

Ovakav pristup omogućuje uravnoteženo učenje preko cijelog genoma.

3.4.3 Pozicijsko kodiranje

Umjesto fiksnih ili naučenih vektora za položaj tokena, Nucleotide Transformer koristi RoPE (Rotary positional embeddings). RoPE implementira pozicijsku informaciju kao rotaciju query i key vektora u self-attention sloju. Ova metoda omogućuje bolje hvatanje relativnih položaja između tokena i bolju generalizaciju na sekvence dulje od onih u trening setu. Tako model zna ne samo koji je token, nego i gdje se nalazi u nizu, i to relativno, a ne samo apsolutno.Također RoPE omogućuje fleksibilnu i kontinuiranu reprezentaciju položaja bez ograničenja na maksimalnu duljinu sekvence.

Kombinacija velikih modela i rotary embeddings u Nucleotide Transformeru rezultirala je boljim performansama u zadacima poput klasifikacije promotorskih sekvenci i predviđanja epigenetskih obilježja, nadmašujući modele bazirane na tradicionalnim embeddingima i klasičnim positional encodingom, uključujući DNABERT i druge.

Nucleotide Transformer predstavlja najopsežniji dosad implementirani model za analizu genomskih sekvenci temeljen na LLM pristupu. U odnosu na DNABERT, NT pokazuje veću sposobnost učenja generaliziranih reprezentacija nukleotidnih nizova, zahvaljujući skalabilnosti, raznolikosti podataka i sofisticiranoj obradi mutacija. Njegove performanse nadmašuju dosadašnje modele u većini biološki relevantnih zadataka, što ga čini ključnim resursom za primjene dubokog učenja u genomici.

4. Usporedba korištenja ugrađenih i klasičnih reprezentacija

U ovom dijelu seminara prikazana je usporedba dvaju pristupa u predstavljanju DNA sekvenci za klasifikacijski zadatak prepoznavanja promotorskih regija. Cilj je bio ispitati učinak ulazne reprezentacije na performanse modela, pri čemu je korišten jednostavan model treniran u dvije varijante: prva koristi klasično one-hot kodiranje DNA sekvenci, dok druga koristi ugrađene reprezentacije dobivene iz prethodno treniranog DNABERT-6 modela.

4.1 Zadatak

U eksperimentu su korištena dva identična modela koji klasificiraju DNA sekvencu kao promotorsku ili nepromotorsku. Prvi model treniran je na one-hot kodiranim sekvencama, pri čemu se svaka nukleotidna baza (A, C, G i T) kodira jednostavnim vektorom duljine četiri, bez semantičkog značenja. Drugi model koristi vektorske reprezentacije dobivene iz DNABERT-6, koje sadržavaju semantičke i kontekstualne informacije o DNA sekvencama. Usporedbom rezultata ovih modela moguće je procijeniti doprinos ugrađenih reprezentacija u učenju i generalizaciji dubokih modela.

4.2 Priprema podataka

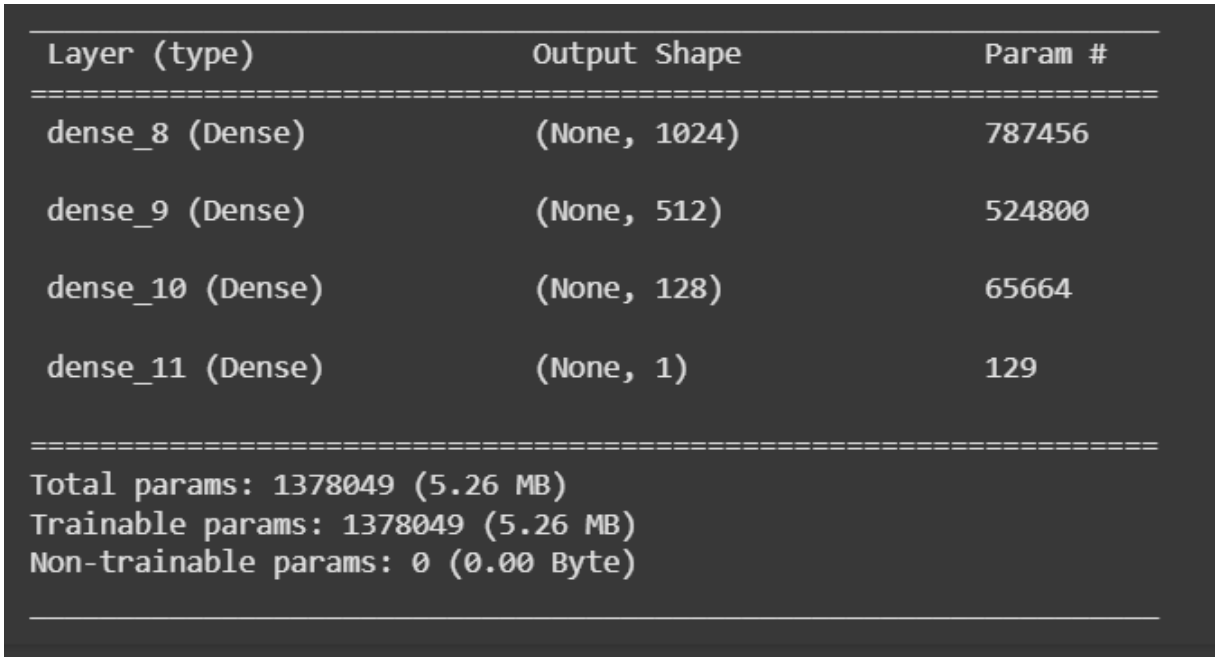
Za klasifikacijski zadatak korišten je skup podataka CNNPromoterData, koji sadrži promotorske i nepromotorske DNA sekvence različitih živih bića. Budući da je DNABERT-6 model treniran isključivo na ljudskom genomu, u ovom eksperimentu korištene su samo ljudske sekvence. Nakon učitavanja, svaka sekvenca označena je pripadnom klasom: 1 ako sadrži promotorsku regiju, odnosno 0 ako ne sadrži. Sekvence su, skupa sa labelama, permutirane i podijeljene na skupove za treniranje, validaciju i testiranje.

U varijanti s ugrađenim reprezentacijama, svaka sekvenca podijeljena je na preklapajuće 6-mere, koji se zatim proslijeđuju kroz tokenizer DNABERT-6 modela. Tokenizer sve 6-merove pretvara u tokene te se dodaju [CLS] (dodaje se na početak niza) i [PAD] (nadopunjuju niz tokena do fiksne duljine) tokeni. Zatim se ti tokeni šalju u DNABERT-6 model koji ih mapira u vektorske reprezentacije, dodaje pozicijsko kodiranje te ih obogati kontekstom sekvence putem self-attention mehanizma. Na izlazu modela sam dobio bogate ugrađene reprezentacije sekvenca.

Za drugu varijantu pripreme podataka korišteno je one-hot kodiranje tako da se svaka nukleotidna baza u DNA sekvencama pretvori u one-hot vektor. I na kraju sam dodao padding da sve sekvence budu iste duljine.

4.3 Model

U obje varijante korišten je isti jednostavni model sastavljen od četiri potpuno povezana sloja. Prva tri sloja koriste ReLU aktivacijsku funkciju, dok posljednji sloj koristi sigmoidnu aktivaciju kako bi model dao vjerojatnost pripadnosti promotorskoj klasi. Model je treniran pomoću Adam optimizatora, a korištena funkcija gubitka je binarna unakrsna entropija.



Slika 4.1: Prikaz modela

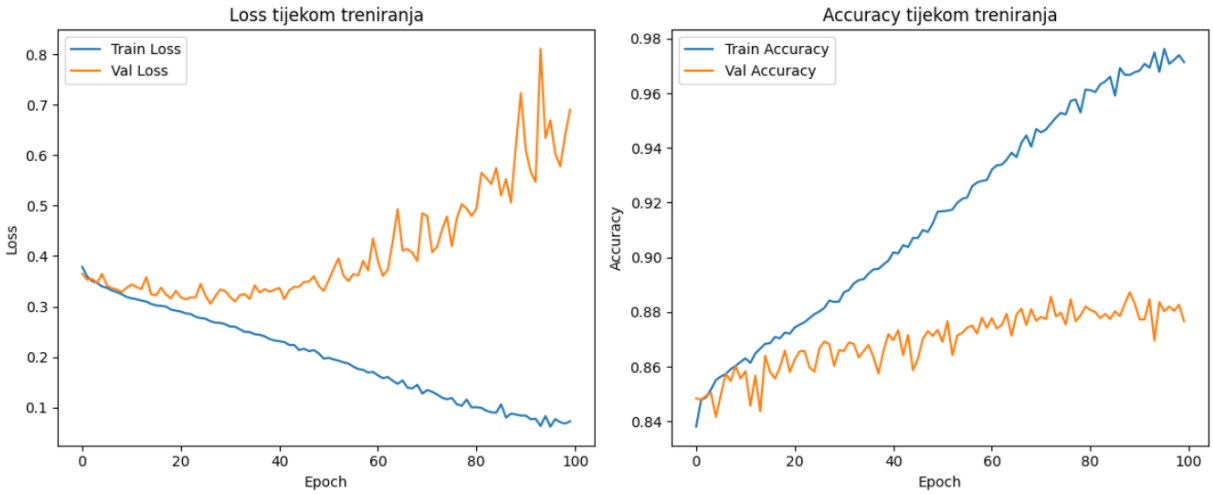
Model treniran na DNABERT reprezentacijama treniran je kroz 100 epoha, dok je model s one-hot reprezentacijama treniran samo 50 epoha, jer se uočilo da već nakon 50 epoha dolazi do znakova prenaučenosti.

4.4 Rezultati i evaluacija

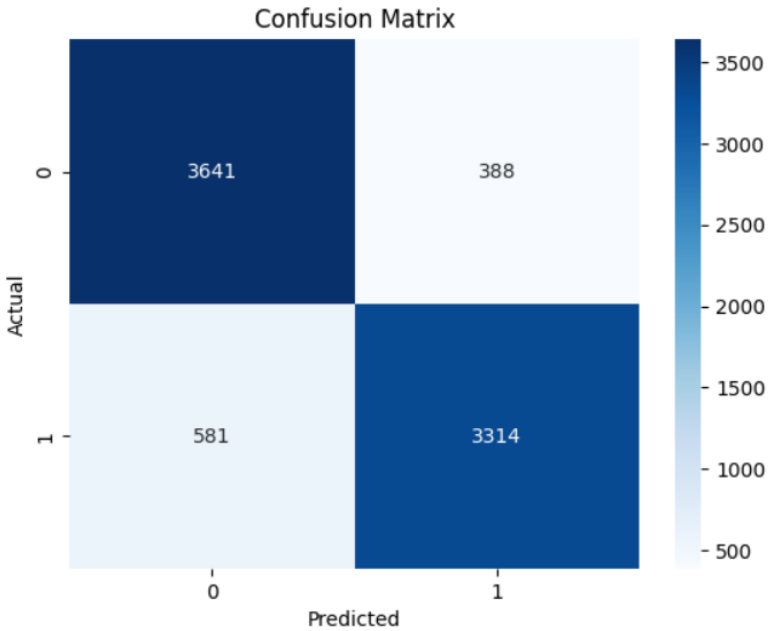
Model koji koristi ugrađene reprezentacije pokazao je stabilan i progresivan proces učenja. Gubitak se postepeno smanjivao kroz epohe, a točnost rasla, što ukazuje na dobru generalizaciju i bolju otpornost na prenaučenost. Na testnom skupu ostvarene su sljedeće metrike:

- Točnost: 0.8777
- Preciznost: 0.8952
- Odziv: 0.8508
- F1 mjera: 0.8724

Vizualizacija procesa treniranja te pripadajuća konfuzijska matrica dodatno potvrđuju visoku razinu ravnoteže između pozitivne i negativne klase, bez prevelikog broja lažno pozitivnih ili lažno negativnih predikcija.



Slika 4.2: Prikaz gubitka i točnosti modela sa ugrađenim reprezentacijama tijekom treniranja

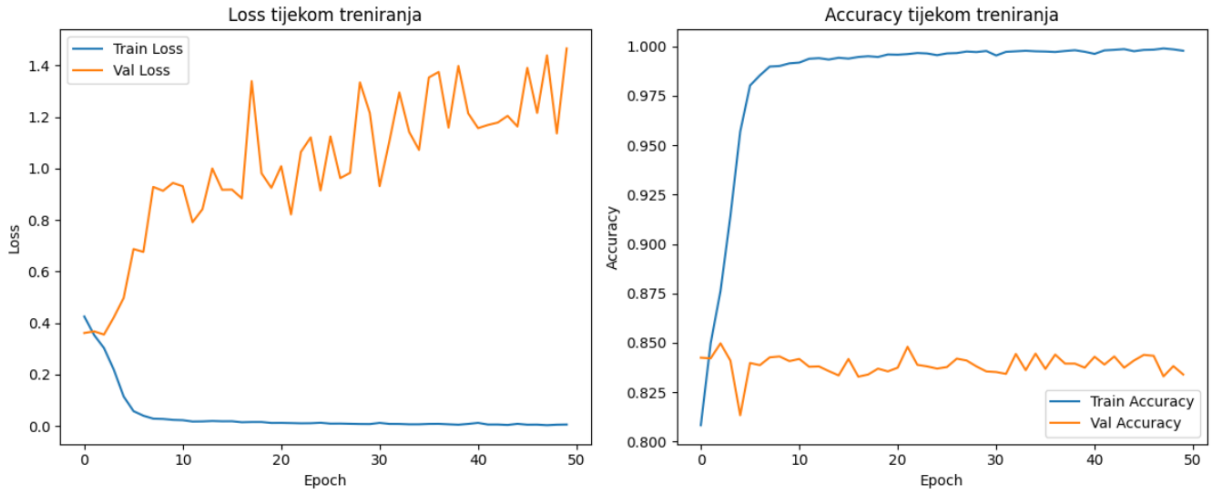


Slika 4.3: Prikaz konfuzijske matrice modela sa ugrađenim reprezentacijama

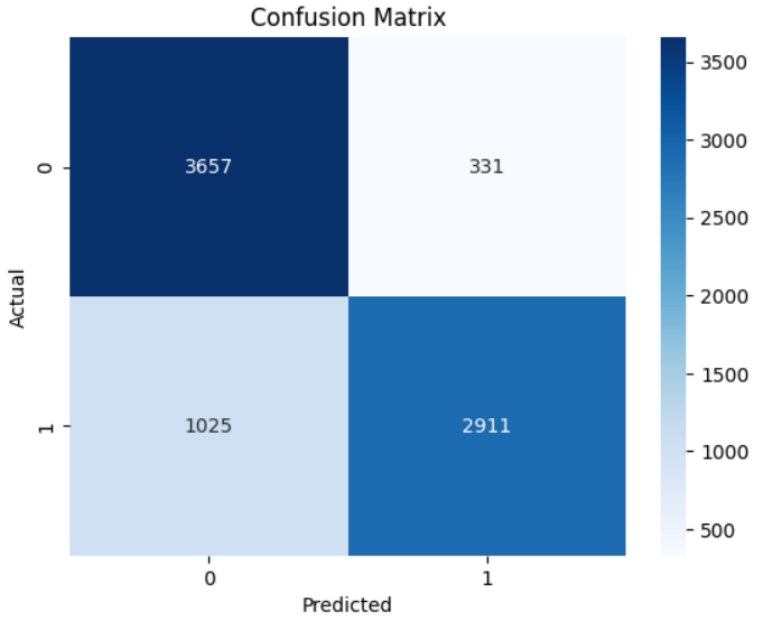
Model koji koristi one-hot kodirane sekvence ostvario je nešto slabije rezultate.

- Točnost iznosi 0.8289
- Preciznost je visoka i iznosi 0.8979
- Odziv je znatno niži: 0.7396, što znači da model češće propušta detektirati promotorske regije.
- F1 mjera iznosi 0.8111, što potvrđuje neravnotežu između sposobnosti detekcije i pouzdanosti pozitivnih predikcija.

Tijekom treniranja vidljivo je da model vrlo brzo uči, no i brzo ulazi u fazu prenaučenosti, gdje se performanse na validacijskom skupu počinju pogoršavati.



Slika 4.4: Prikaz gubitka i točnosti modela sa one-hot reprezentacijama tijekom treniranja



Slika 4.5: Prikaz konfuzijske matrice modela sa one-hot reprezentacijom

Usporedba ova dva pristupa pokazuje da model s ugrađenim reprezentacijama bolje generalizira na neviđene podatke i ravnomjernije balansira između preciznosti i odziva. One-hot kodiranje je jednostavno i učinkovito u određenim slučajevima, no gubi kontekstualne i semantičke informacije, što se odražava na nižu sposobnost modela da detektira kompleksne obrasce u DNA sekvenci. Ugrađene reprezentacije, s druge strane, iskorištavaju znanje stečeno tijekom pretreniranja na velikim genomskim skupovima, što omogućuje dublje razumijevanje strukture i funkcije sekvence. Takve reprezentacije posebno su korisne kod zadataka s ograničenim brojem označenih podataka, što je često slučaj u bioinformatici.

5. Zaključak

Predstavljenim eksperimentima i analizom suvremenih pristupa nedvojbeno je potvrđena iznimna učinkovitost i potencijal ugrađenih reprezentacija DNA sekvenci, posebno onih dobivenih putem sofisticiranih transformer arhitektura kao što su DNABERT i nucleotide transformer. Ove reprezentacije znatno nadmašuju tradicionalne metode poput one-hot kodiranja jer omogućuju modelima duboko razumijevanje semantičkih i kontekstualnih odnosa među nukleotidima i k-merima. To rezultira značajnim poboljšanjem točnosti, robusnosti i sposobnosti generalizacije u zadacima klasifikacije i analize genetskih sekvenci, što je kritično za učinkovito snalaženje u eksploziji genomskih podataka.

Rad ističe presudnu važnost korištenja velikih, raznolikih i biološki relevantnih skupova podataka za predtreniranje ovih modela, što im omogućuje da nauče opće obrasce i "jezik" DNA prije nego što se finim podešavanjem prilagode specifičnim zadacima. Također, naglašava se važnost pažljivog odabira modela i tokenizacijskih strategija koje su optimizirane za specifičnosti genomskih podataka. U budućnosti se očekuje daljnji napredak kroz razvoj još većih modela i inovativnih arhitektura, što će dodatno unaprijediti mogućnosti analize genetskih sekvenci. Takav napredak ima ogroman potencijal za transformaciju precizne medicine, dijagnostike bolesti, razvoja novih terapija i razumijevanja kompleksnih bioloških procesa. Ugrađene reprezentacije su, dakle, temelj za daljnji razvoj polja genomike i bioinformatike vođene dubokim učenjem.

6. Sažetak

Ovaj rad temeljito istražuje transformativnu ulogu ugrađenih reprezentacija (embeddinga) u analizi DNA sekvenci pomoću dubokog učenja. Tradicionalne metode, poput one-hot kodiranja nukleotida, pokazuju značajna ograničenja u hvatanju kompleksnih bioloških odnosa i skalabilnosti zbog svoje kontekstualno siromašne prirode. U suprotnosti s tim, ugrađene reprezentacije, inspirirane uspjesima iz obrade prirodnog jezika (poput Word2Vec i FastText), omogućuju preslikavanje k-merova (kratkih podnizova DNA) u kontinuirani, niskodimenzionalni vektorski prostor. U tom prostoru se semantički i biološki slični k-merovi nalaze blizu jedni drugima, omogućujući modelima dubljeg učenja da učinkovitije prepoznaju složene obrasce.

Fokus je stavljen na napredne modele temeljene na transformer arhitekturi, kao što su DNABERT i nucleotide transformer. Detaljno je objašnjeno kako ovi modeli, koristeći mehanizme poput tokenizacije (k-mer ili 6-mer), pozicijskog kodiranja (uključujući RoPE u nucleotide transformeru) i self-attention mehanizma, uče bogate kontekstualne reprezentacije DNA sekvenci iz masivnih genomskih skupova podataka. Eksperimentalni dio rada demonstrira usporedbu performansi jednostavnog klasifikacijskog modela na zadatku prepoznavanja promotorskih regija: jednom koristeći klasično one-hot kodiranje, a drugi put bogate ugrađene reprezentacije dobivene iz predtreniranog DNABERT modela. Rezultati jasno pokazuju superiornost ugrađenih reprezentacija u smislu točnosti, preciznosti, odziva i F1 mjere, kao i znatno bolju generalizacijsku sposobnost i manju podložnost prenaučenosti. Ova studija naglašava da ugrađene reprezentacije omogućuju modelima dubokog učenja dublje razumijevanje biološkog jezika DNA, što je ključno za napredak u bioinformatici.

Ključne riječi:
DNABERT;ugrađene;reprezentacije;embedding;Word2Vec;bioinformatika;k-mer

.

7. Literatura

[1] https://www.ibm.com/think/topics/word-embeddings

[2] https://medium.com/@manansuri/a-dummys-guide-to-word2vec-456444f3c673

[3] https://www.turing.com/kb/guide-on-word-embeddings-in-nlp

[4] https://edutorij-admin-api.carnet.hr/storage/extracted/074ffbb3-a1b7-4fe1-9f4a-1ea3539d642d/biologija-1/m02/j04/index.html

[5] Ji, Y., Zhou, Z., Liu, H., Davuluri, R.V. DNABERT: pre-trained Bidirectional Encoder Representations from Transformers model for DNA-language in genome. Bioinformatics. 2021

[6] Ferré, T., Clauwaert, J., Decroly, O., Louppe, G., van den Oord, A. Nucleotide Transformer: Building and evaluating foundation models for DNA. Nature Methods. 2024